

# Informática para Economistas

## Introducción a Rstudio

**Msc. Ciro Ivan Machacuay Meza**

Universidad Nacional del Centro del Perú

2025



# Contenido

- 1 Introducción
- 2 Modo de trabajo
- 3 Tipos de objetos
- 4 Operadores y funciones
- 5 Listas y data
- 6 Subsetting and Element Extraction (indexación)
- 7 Guardar resultados
- 8 Missing value
- 9 Vectorización de funciones\*
- 10 Referencias

# Section 1

## **Introducción**

# Introducción

- “La programación es una habilidad vital para todos los que trabajan intensamente con datos”(Grolemund, 2014).
- R es un lenguaje de programación de distribución libre creado en 1993 por **Ross Ihaka** y **Robert Gentleman**.
- R funciona como un ambiente en el que se aplican técnicas estadísticas en lugar de una acumulación gradual de herramientas muy específicas y poco flexibles (Santana y Farfán, 2014).

# Introducción

## ¿Por qué R?

- 1) **Es gratis.**
- 2) Curva de aprendizaje plana, pero con alta potencia.
- 3) Es flexible y de fácil acceso.
- 4) Se actualiza constantemente (esto puede traer problemas\*), contrario a los programas comerciales.
- 5) Incorporación anticipada de técnicas estadísticas.
- 6) Una colección amplia, coherente e integrada de herramientas para el análisis de datos (Venables y Smith, 2021).
- 7) **Reproducible**, adios cajas negras (Castro, 2021).

# Introducción

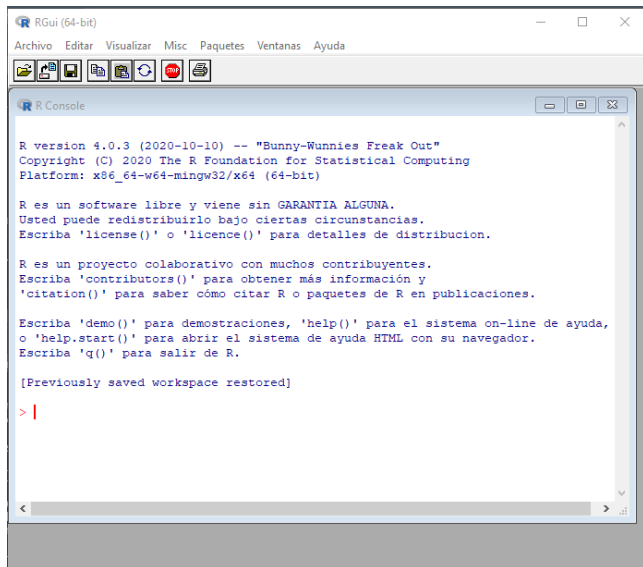
R se divide en dos partes:

- 1) **El sistema base**, que puede ser descargado de la página oficial del proyecto <https://www.r-project.org/> -en su última versión o cualquiera de las anteriores-; y,
  - 2) **Paquetes modulares (packages)**, cuya viabilidad es posible gracias a la facultades de R para desarrollar nuevas herramientas.
- Nota: Las **actualizaciones** incluyen cambios y mejoras, pero pueden volver disfuncionales los programas ya realizados.

## Section 2

# **Modo de trabajo**

# Ambiente R



```
RGui (64-bit)

Archivo  Editar  Visualizar  Misc  Paquetes  Ventanas  Ayuda

R Console

R version 4.0.3 (2020-10-10) -- "Bunny-Wunnies Freak Out"
Copyright (C) 2020 The R Foundation for Statistical Computing
Platform: x86_64-w64-mingw32/x64 (64-bit)

R es un software libre y viene sin GARANTIA ALGUNA.
Usted puede redistribuirlo bajo ciertas circunstancias.
Escriba 'license()' o 'licence()' para detalles de distribucion.

R es un proyecto colaborativo con muchos contribuyentes.
Escriba 'contributors()' para obtener más información y
'citation()' para saber cómo citar R o paquetes de R en publicaciones.

Escriba 'demo()' para demostraciones, 'help()' para el sistema on-line de ayuda,
o 'help.start()' para abrir el sistema de ayuda HTML con su navegador.
Escriba 'q()' para salir de R.

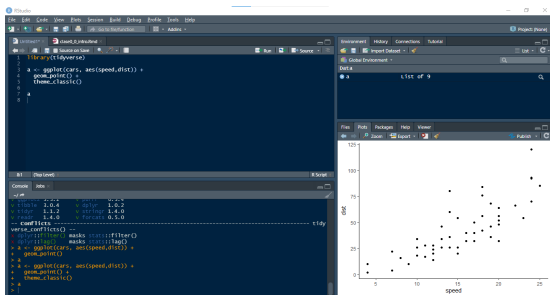
[Previously saved workspace restored]

> |
```



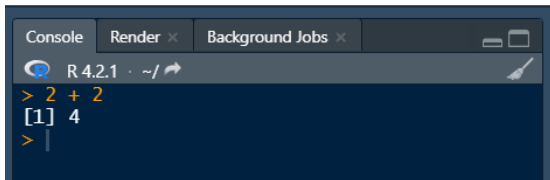
# Ambiente Rstudio

- Elementos claves de R (Davies, 2016):
  - Console: la consola es donde insertamos ordenes.
  - Script: copilación de sentencias o codigos de trabajo.
  - Workspaces: ambiente donde se encuentran todos los objetos creados.
  - Working Directory: ruta o carpeta donde R esta guardando o buscando información.



# Modo iterativo

- Instalado el programa, el modo iterativo representa la forma de uso más sencillo.
- En la consola, el “prompt”, representado por el smbolo `>` (mayor que), indica el lugar donde se escriben las órdenes (o comandos). Cuando introduces una **expresión** en la línea de comandos y das ENTER.



The screenshot shows the R console window with tabs for 'Console', 'Render', and 'Background Jobs'. The console displays the R version 'R 4.2.1' and the prompt '>'. The user has entered the expression '2 + 2', and the console has responded with '[1] 4'. The prompt '>' is now on a new line, ready for the next command.

```
R 4.2.1 · ~/ ➔  
> 2 + 2  
[1] 4  
> |
```

# Modo iterativo

- R puede ser usado como una calculadora (modo de trabajo iterativo):

```
2+2
```

```
## [1] 4
```

```
2.3*2
```

```
## [1] 4.6
```

```
2-3; 2^3; 8/2
```

```
## [1] -1
```

```
## [1] 8
```

```
## [1] 4
```

# Operador de asignación

- R es un lenguaje de programación, normalmente la razón de su uso es automatizar los procesos y evitar la repetición de tareas. Por tanto, podemos guardar los resultados en objetos.
- La manera de asignar un valor a un **objeto** (variable) en R, es usar el operador de asignación ( $\leftarrow$ , equivalente al signo de igual).

```
result<-5*6    # assign("result", 5*6)
#imprimir resultados
result
```

```
## [1] 30
```

```
#usarlo en otras operaciones
result+4
```

```
## [1] 34
```

# Operador de asignación

- Esta forma de asignar objeto en lugar de “=” (Respuesta de chat gpt3.0):
  - Evita la **confusión entre la asignación “=” e igualdad “==”**.
  - **Facilidad de lectura:** El uso de “<=” puede hacer que el código sea más legible.
  - Posibles **conflictos con funciones:** El uso de = como operador de asignación podría crear conflictos con el uso de = en argumentos de funciones.

# Comentarios

- El signo # se utiliza para **introducir comentarios**.
- R es **case sensitive**.

# Operador de asignación

- Por tanto, las órdenes introducidas en R pueden ser **expresiones** (se imprime y pierde su valor) o **asignaciones** (no se imprime y guarda su valor).
- Podemos usar operaciones o funciones alimentadas por argumentos (obligatorios u opcionales).

```
x <- c(7,8,15)
a <- sum(x)
a
```

```
## [1] 30
```

# Combinar operaciones

- Podemos utilizar las propiedades de vectorización para recuperar valores agregados aplicando operaciones sobre cada uno de los valores del vector.
- Ejemplo para el calculo de la varianza muestral:

```
sum(x^2)
```

```
## [1] 338
```

```
sum((x-mean(x))^2)/(length(x)-1)
```

```
## [1] 19
```

```
var(x)
```

```
## [1] 19
```



# Uso universal

- Pensemos siempre en utilizar sentencias que no necesiten la modificación humana ante cambios en los datos:
- En lugar de:

```
edad <- c(21,16,28,8)
sum(edad)/4
```

```
## [1] 18.25
```

- Usemos:

```
edad2 <- c(21,16,28,8,22)
sum(edad2)/length(edad2)
```

```
## [1] 19
```

# Continuidad de ordenes

- Las órdenes se separan en líneas o mediante punto y coma (;). En caso de no estar completa, se muestra el signo + en la consola, hasta esta ser completada.

```
max(7,8,15)
```


```
## [1] 15
```

```
max(7,8,  
    15)
```

```
## [1] 15
```

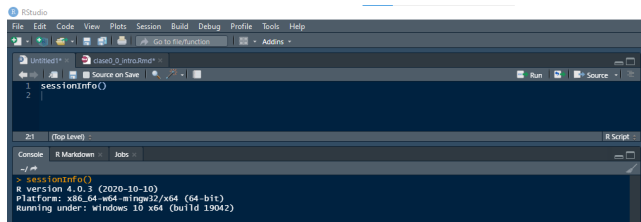
# Historial de comandos

- La flecha arriba, Ctrl + Up o el comando `history()` (últimos 25 comandos), permiten recuperar las órdenes ejecutadas.



# Modo programador

- Para evitar tener que guardar cada sentencia, podemos acceder al modo programador trabajando sobre un script (sessionInfo()).
- SIEMPRE trabajar modo programador.



The screenshot shows the RStudio environment. The top menu bar includes File, Edit, Code, View, Plots, Session, Build, Debug, Profile, Tools, and Help. Below the menu is a toolbar with icons for file operations and a 'Go to file/function' search bar. The main editor window displays a script named 'class0\_0\_intro.Rmd' with the following code:

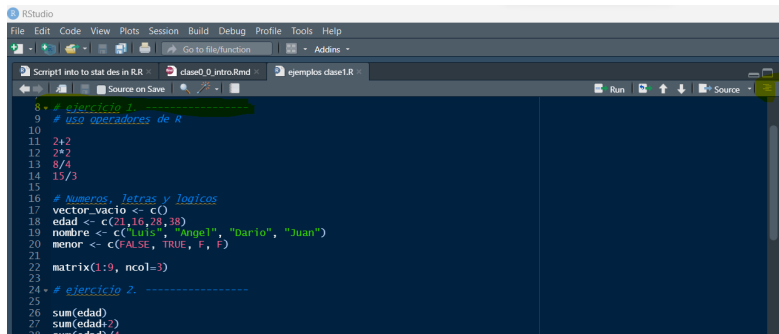
```
1 sessionInfo()
2
```

The bottom-left pane shows the 'Console' tab with the output of the 'sessionInfo()' command:

```
> sessionInfo()
R version 4.0.3 (2020-10-10)
Platform: x86_64-w64-mingw32/x64 (64-bit)
Running under: windows 10 x64 (build 19042)
```

# Modo programador

- Divide tu **script** en secciones (agregando - seguidos al final del comentario —) permitirá ir organizando mejor sus trabajos.



```
8 - # ejercicio 1. -----
9 # uso operadores de R
10
11 2+2
12 2*2
13 8/4
14 15/3
15
16 # Numeros, letras y logicos
17 vector_vacio <- c()
18 edad <- c(21,16,28,38)
19 nombre <- c("Luis", "Angel", "Dario", "Juan")
20 menor <- c(FALSE, TRUE, F, F)
21
22 matrix(1:9, ncol=3)
23
24 - # ejercicio 2. -----
25
26 sum(edad)
27 sum(edad*2)
28 sum(edad)/4
```

# Modo programador

- Escribe **scripts** para que el resto te entienda:

Ejemplo 1:

```
x <- 2 + 3
```

Ejemplo 2: el nombre de los objetos deben ser explicativos y las sentencias comentadas.

```
# Suma las edades de los individuos más jóvenes  
edad_sum <- 2 + 3
```

## Section 3

# Tipos de objetos

# Objetos

Los **objetos** se pueden clasificar en:

- 1) **Atómicos**, donde todos los elementos [texto, números (enteros, doble), lógicos] son del mismo tipo: (vectores y matrices).

```
nombre<-"Juanga"
hombre <-TRUE
edad <-23
```

- 2) **Rekursivos**, pueden combinar una colección de objetos diferentes (dataframe, listas).

```
data.frame(nombre,hombre,edad)
```

```
##  nombre hombre edad
## 1  Juanga   TRUE   23
```



# Tipos de vectores: números

- Los vectores numérico. Es el tipo de datos con mayor importancia o principal uso, agrupados en numeric, integer y complex. El mismo, permite almacenar vectores y matrices.
- Estos son objetos comunes, permiten representar magnitudes. la función **concatenar** `c()` elementos del mismo tipo.

```
v1 <- 3
v2 <- 2+4i
v3 <- c(1L,2L,3L)
v4 <- c(1:3)
ing <- c(17.3,21.1252,23.356)

assign("edad1", c(17,21,23))
```

# Objetos

- Cuando creamos un vector, R crea un vector con los valores (1, 2, 3), y lo vincula a un objeto llamado v3, por tanto, *puede pensar en un nombre como una referencia a un valor* (Hadley, 2020).

```
v3 <- c(1,2,3)
```

```
v4 <- v3
```

- El nombre asignado no puede comenzar con dígitos o símbolos, tampoco se pueden usar palabras reservadas: TRUE, NULL, if... Otros nombres como C, mean, se pueden usar, pero no son recomendable.

# Tipos de vectores: texto

- Caracteres (letras). Estas expresiones se denotan entre comillas simples o dobles.

```
x <- c("a", "b", "c")  
class(x)
```

```
## [1] "character"
```

```
nombres<-c("Maria", "Jesus")  
nombres
```

```
## [1] "Maria" "Jesus"
```

# Tipos de vectores: lógicos

- Los objetos lógicos representan valores binarios (falso (0) y verdadero (1)).
- En R, el valor falso se representan por FALSE (=0) o únicamente por la letra F mayúscula, el valor verdadero es representado por TRUE (=1) o por la letra T.

```
x<-c(T,T,F,F,T)
x
```

```
## [1] TRUE TRUE FALSE FALSE TRUE
```

```
# representación en números
as.numeric(x)
```

```
## [1] 1 1 0 0 1
```

```
x*1
```

```
## [1] 1 1 0 0 1
```

# Asignando nombres

- Inserte un vector llamado `clientes` que indique la cantidad de clientes atendidos por una peluquero durante la semana:

```
cliente <- c(8,15,13,22,24)
cliente
```

```
## [1]  8 15 13 22 24
```

```
names(cliente) <- c("Lun", "Mar", "Mie", "Jue", "Vie")
cliente
```

```
## Lun Mar Mie Jue Vie
##    8  15  13  22  24
```

```
names(cliente)
```

```
## [1] "Lun" "Mar" "Mie" "Jue" "Vie"
```

# Factores nominales

```
sexo <- c("m", "f", "m", "f", "m", "m")
sexofactor <- factor(sexo, levels = c("m", "f"))

table(sexo)
```

```
## sexo
## f m
## 2 4
```

```
table(sexofactor)
```

```
## sexofactor
## m f
## 4 2
```

```
sexofactor <- factor(sexo, levels=c("m", "f"), labels=c("Hombre", "Mujer"))
table(sexofactor)
```

```
## sexofactor
## Hombre  Mujer
##      4      2
```

# Vectores de secuencias y repeticiones

```
1:10 # del 1 al 10
```

```
## [1] 1 2 3 4 5 6 7 8 9 10
```

```
10:1 # del 10 al 1
```

```
## [1] 10 9 8 7 6 5 4 3 2 1
```

```
seq(1,10) #vector que vaya desde 1 a 10
```

```
## [1] 1 2 3 4 5 6 7 8 9 10
```

```
seq(1,10,by=2) # fijar intervalos de la secuencia
```

```
## [1] 1 3 5 7 9
```

```
seq(1,10,length=3) # fijar longitud de la secuencia
```

```
## [1] 1.0 5.5 10.0
```

# Vectores de secuencias y repeticiones

```
rep(c(1:3), time=2)
```

```
## [1] 1 2 3 1 2 3
```

```
rep(c(1:3), each=2)
```

```
## [1] 1 1 2 2 3 3
```



# Matrices

- Desde el punto de vista del lenguaje, una matriz es un vector con un atributo adicional.
- Los datos en R se van rellenando columna a columna de izquierda da derecha. Aunque también se puede especificar el orden deseado.

```
matrix(1:12, nrow=4, ncol=3)
```

```
##      [,1] [,2] [,3]
## [1,]    1    5    9
## [2,]    2    6   10
## [3,]    3    7   11
## [4,]    4    8   12
```

```
(m1<-matrix(1:12, nrow=4, ncol=3, byrow=TRUE))
```

```
##      [,1] [,2] [,3]
## [1,]    1    2    3
## [2,]    4    5    6
## [3,]    7    8    9
## [4,]   10   11   12
```

# Matrices

- A las matrices creadas podemos asignar nombres y acceder a sus elementos a partir de estos, las funciones son `colnames` y `rownames`.

```
colnames(m1)<-c("edad","peso","altura")
rownames(m1)<-c("Perla","Juan","Eva","Alex")
m1
```

```
##      edad peso altura
## Perla    1    2      3
## Juan     4    5      6
## Eva      7    8      9
## Alex    10   11     12
```

# Modo programador

- Un modo de trabajo alternativo consiste en crear un **Script** que permita guardar instrucciones, y nos hace libre de realizar instrucción por instrucción. Para esto, escribimos los codigos en un **Script**.
  - Ctrl + Shift + N / file + new file + Script.
  - Ctrl + Shift + R (insertar secciones en un Script).
  - Ctrl + Shift + C (insertar comentarios (nos me gusta)).
  - Ctrl + Shift + N (new Script).
  - Ctrl + Shift + H (cambiar directorio de trabajo).
  - Ctrl + Shift + K (Compile Notebook).
  - Ctrl + Shift + Alt + M (renombrar en conjunto. OJO).
  - q() cerrar el programa.

# Paquetes

- Muchas herramientas de R no están disponible en el paquete base, no obstante, podemos contar con ella mediante librerías. Una forma de adherirlas:

```
# install.packages(stargazer)  
library(stargazer)  
  
## Lista de todos los paquetes instalados:  
list_pac <- rownames(installed.packages())
```

- Otra alternativa para utilizar las funciones de un paquete consiste en utilizar el operador `::` para adjuntar la función a R sin necesidad de cargar el paquete:

```
# stargazer::stargazer()
```

## Section 4

# Operadores y funciones

# Operaciones

- Sobre los objetos de R, utilizando diversos operadores, podemos obtener diferentes resultados. Los operadores más frecuentemente usados son:

Aritméticos	Relacionales	Lógicos	Especiales	Propios
+ Suma	== igualdad	& Y lógico	%% residuo	
- Resta	!= Diferente	! No lógico	%in% contenido	%!in%
* Multiplicación	< Menor que	O lógico	grep cuasi igualdad	
/ División	> Mayor que	all	< -- > assignment	
^ Potencia (**)	<= Menor o igual	any	[] \$ indexación	
sqrt()	>= Mayor o igual	&&,	> pipe	% > %
log(), exp()		xor		

Fuente: elaborado a partir de "The R Book".

# Operaciones aritméticas con vectores

```
v<-c(6,4,8)
```

```
v+3
```

```
## [1] 9 7 11
```

```
v/2
```

```
## [1] 3 2 4
```

```
v+c(1,2,3)
```

```
## [1] 7 6 11
```

```
v*c(1,2,3)
```

```
## [1] 6 8 24
```

```
v^(2:4)
```

```
## [1] 36 64 4096
```

# Funciones

- Las siguientes funciones proporcionan medidas de resumen de los estadísticos de un vector (Narayanachar, et al, 2016).

```
x <- c(2,5,8,6,7,9,10,15,-1,8)
```

```
sum(x); mean(x); max(x)
```

```
## [1] 69
```

```
## [1] 6.9
```

```
## [1] 15
```



# Funciones

- Los operadores de R son una función:

```
5+5
```

```
## [1] 10
```

```
`+`(5,5)
```

```
## [1] 10
```

# Funciones propias

- Podemos crear funciones a partir de nuestras necesidades:

```
coefvar <- function(x) sd(x)/mean(x)  
coefvar(x)
```

```
## [1] 0.6352244
```

```
MyVar <- function(x){sum((x-mean(x))^2)/(length(x)-1)}  
MyVar(x)
```

```
## [1] 19.21111
```

```
var(x)
```

```
## [1] 19.21111
```

# Funciones estadísticas

- También, podemos acceder a una importante batería de funciones estadísticas:

Posición	Dispersión	Forma	Asociación	Resumen
<code>mean(x)</code>	<code>var(x)</code>	<code>skewness(x)</code>	<code>cov(x)</code>	<code>summary</code>
<code>quantile(x,perc)</code>	<code>sd(x)</code>	<code>kurtosis(x)</code>	<code>cor(x)</code>	
<code>mean(x, trim=0.1)</code>	<code>range(x)</code>			
<code>median(x)</code>	<code>IQR(x)</code>			

- Funte: elaborado a partir de (Harrison, 2020)

# funciones para strings

```
substr('tragabala', start = 1, stop = 4)
```

```
## [1] "trag"
```

```
nchar('tragabala') #cuenta caracteres, !=length
```

```
## [1] 9
```

```
# Última tres letra
```

```
substr('tragabala', nchar('tragabala')-3+1, nchar('tragabala'))
```

```
## [1] "ala"
```

```
# Sustituir elementos
```

```
chartr("a","A", "tragabala")
```

```
## [1] "trAgAbAlA"
```

# Operaciones aritméticas en funciones

- Los operadores pueden aparecer en formas de funciones:

```
log(2)
```

```
## [1] 0.6931472
```

```
sqrt(9)
```

```
## [1] 3
```

```
abs(-7)
```

```
## [1] 7
```

```
round(12.3252,2)
```

```
## [1] 12.33
```

```
8 %% 2
```

```
## [1] 0
```

# Operadores relacionales

- Los operadores relacionales permiten comparar elementos de un objeto, comparar objetos, indexar mediante operadores para generar vectores lógicos y establecer condicionales.

```
edad<-c(8,4,2,6,10,9)
```

```
edad>6
```

```
## [1] TRUE FALSE FALSE FALSE TRUE TRUE
```

# Operadores relacionales

- Podemos usar los vectores lógicos para contabilizar la cantidad de observaciones que cumplen con una condición:

```
sum(edad<=6)
```

```
## [1] 3
```

- Recuperar los valores de un vector que cumplen determinada condición:

```
(edad<=6)*edad #coloca cero a los valores que no cumplen la condición
```

```
## [1] 0 4 2 6 0 0
```

```
sum((edad<=6)*edad)
```

```
## [1] 12
```

# Lógicos

Estos operadores operan bajo los criterios del **álgebra de sucesos**.

- **Unión**  $\cup$ . La unión de sucesos  $A \cup B$  que ocurre si solo si, al menos uno de los dos sucesos ocurre (se lee como suma de A y B; A o B; A unido a B.).
- **Intersección**  $\cap$ . Producto de sucesos. Es el suceso que ocurre, solo si ocurre tanto A como B.

```
x<-c(T,T,F,F); y<-c(T,F,T,F)
```

```
y0x <- y | x
```

```
yYx <- y & x
```

```
cbind(x,y,y0x,yYx)
```

```
##           x      y    y0x    yYx
## [1,]  TRUE  TRUE   TRUE   TRUE
## [2,]  TRUE FALSE   TRUE  FALSE
## [3,] FALSE  TRUE   TRUE  FALSE
## [4,] FALSE FALSE  FALSE  FALSE
```



# Lógicos

- Usando una base de datos ilustrativa, podemos observar el uso de estos operadores:

```
edaM <- edad>5
edaMh <- edad>5 & sexofactor=="Hombre"
edaMhm <- edad>5 | sexofactor=="Hombre"
xorEdadMh <- xor(edad>5, sexofactor=="Hombre")
```

```
(Mydatos <- data.frame(sexofactor,edad, edaM, edaMh, !edaMh, edaMhm, xorEdadMh))
```

##	sexofactor	edad	edaM	edaMh	X.edaMh	edaMhm	xorEdadMh
## 1	Hombre	8	TRUE	TRUE	FALSE	TRUE	FALSE
## 2	Mujer	4	FALSE	FALSE	TRUE	FALSE	FALSE
## 3	Hombre	2	FALSE	FALSE	TRUE	TRUE	TRUE
## 4	Mujer	6	TRUE	FALSE	TRUE	TRUE	TRUE
## 5	Hombre	10	TRUE	TRUE	FALSE	TRUE	FALSE
## 6	Hombre	9	TRUE	TRUE	FALSE	TRUE	FALSE

# Lógicos

- Anexo los resultados de distintas combinaciones cuando aparecen valores NA:

```
x<-c(T,T,F,F,NA,NA,NA); y<-c(T,F,T,F,T,F,NA)

y0x <- y | x
yYx <- y & x
xorxy <- xor(x,y) #tiene una de los dos, pero no las dos

cbind(x,y,y0x,yYx,xorxy, !y0x,!yYx)
```

##		x	y	y0x	yYx	xorxy		
##	[1,]	TRUE	TRUE	TRUE	TRUE	FALSE	FALSE	FALSE
##	[2,]	TRUE	FALSE	TRUE	FALSE	TRUE	FALSE	TRUE
##	[3,]	FALSE	TRUE	TRUE	FALSE	TRUE	FALSE	TRUE
##	[4,]	FALSE	FALSE	FALSE	FALSE	FALSE	TRUE	TRUE
##	[5,]	NA	TRUE	TRUE	NA	NA	FALSE	NA
##	[6,]	NA	FALSE	NA	FALSE	NA	NA	TRUE
##	[7,]	NA	NA	NA	NA	NA	NA	NA

# Funciones lógicas

- Los operadores también nos permiten verificar si alguna condición se cumple en todas nuestras observaciones:

```
#al menos 1 es hombre?  
any(sexofactor=="Hombre")
```

```
## [1] TRUE
```

```
#son todos hombres?  
all(sexofactor=="Hombre")
```

```
## [1] FALSE
```

# Práctica

- Suponga que a su institución financiera se acercan cinco individuos a solicitar créditos, y del formulario de solicitud ha completado la siguiente información:

```
# id=1; nombre=Juan; edad=21; ingreso=15000; calific=a.  
# id=2; nombre=Jose; edad=26; ingreso=22500; calific=b.  
# id=3; nombre=Ara; edad=40; ingreso=38520; calific=c.  
# id=4; nombre=Noel; edad=42; ingreso=32500; calific=b.  
# id=5; nombre=luisa; edad=17; ingreso=32500; calific=a.
```

- La política de préstamo de la empresa, indica que se asignan prestamos aquellos individuos mayores de edad, con ingresos superiores a los 30 mil pesos y una calificación crediticia de a o b.
  - Inserte los vectores y cree la base correspondiente en un data.frame.
  - Indique cuales individuos calificarían para el crédito, creando un vector lógico que asuma el valor de 1 para aquellos individuos que califican para crédito.

# Pertenece a (in)

- En caso que deseamos verificar la pertenencia a un conjunto de valores, en lugar de una solo:

```
edad %in% c(8,1,10)
```

```
## [1] TRUE FALSE FALSE FALSE TRUE FALSE
```

```
identical(edad %in% c(8,1), edad==8 | edad==1)
```

```
## [1] TRUE
```

```
sum(edad %in% c(8,1,10))
```

```
## [1] 2
```

# No pertenece a (in)

- R permite crear operadores lógicos en función de nuestras necesidades: suponga desea negar contenido en, identificando ahora las edades que no corresponden a determinados años.
- Luego, este operador puede crearse o manejarse igual que cualquier otro operador.

```
`%!in%` = Negate(`%in%`)
edad
```

```
## [1] 8 4 2 6 10 9
```

```
edad %!in% c(8,1,10)
```

```
## [1] FALSE TRUE TRUE TRUE FALSE TRUE
```

# Igualdad parcial (grep)

- Hasta ahora, hemos estado interesados en la igualdad total de los valores de los objetos, sin embargo, podemos estar interesados en identificar aspectos parciales de los valores de una celda.
  - Iniciales del telefono de una zona geográfica.
  - Palabras claves incluidas en un texto.
- En el ejemplo siguiente se identifican los textos que contienen A o a (A|a+ ver expresiones regulares para más detalles):

```
(nombres<-c("Maria", "Jesus", "Juan", "Antonio", "Ana"))
```

```
## [1] "Maria" "Jesus" "Juan" "Antonio" "Ana"
```

```
grep("A|a+", nombres)
```

```
## [1] 1 3 4 5
```

# Sorting, Ranking and Ordering

```
ranks<-rank(edad)
sorted<-sort(edad)
ordered<-order(edad)

data.frame(edad, ranks, sorted, ordered)
```

##	edad	ranks	sorted	ordered
## 1	8	4	2	3
## 2	4	2	4	2
## 3	2	1	6	4
## 4	6	3	8	1
## 5	10	6	9	6
## 6	9	5	10	5



## Section 5

# Listas y data

# Data frame

- Un data frame es un marco de datos (Base de datos p).
- Los **nombres de las variables** deben ser claros y seguir leyes.

Vectores:

```
nota <- c(91,76,68,78)
nombre <- c("Luis", "Angel", "Dario", "Juan")
menor <- c(FALSE, TRUE, F, F)
```

Data frame:

```
base_datos<-data.frame(nota,nombre,menor)
base_datos
```

```
##   nota nombre menor
## 1   91   Luis FALSE
## 2   76  Angel  TRUE
## 3   68  Dario FALSE
## 4   78   Juan FALSE
```

# Cargar base de datos desde Excel

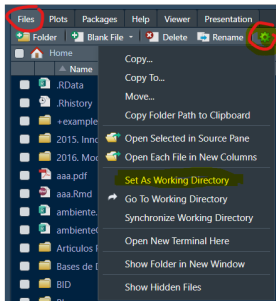
- La mayor parte del tiempo nuestros datos deben ser **importados** de alguna plataforma externa. R contiene una amplia cantidad de herramientas para esta tarea.
  - `read.csv("data.csv")`

# Cargar base de datos desde Excel

- Es importante aquí entender el **directorio de trabajo**:

```
getwd() #setwd()
```

```
## [1] "C:/Users/Nerys Ramirez/Dropbox/Tidyverse in R/Clase 0 Introduccion al ambien
```



# Cargar base de datos desde Excel

- la función **read\_excel** del paquete **readxl**, permite **importar datos desde Excel**.


```
library(tidyverse)
wage1_excel <- readxl::read_excel("wage1.xlsx")
head(wage1_excel, 2)
```

```
## # A tibble: 2 x 24
##   wage educ exper tenure nonwhite female married numdep smsa northcen south
##   <dbl> <dbl> <dbl> <dbl>   <dbl> <dbl>   <dbl> <dbl> <dbl>   <dbl> <dbl>
## 1  3.1    11     2      0       0      1      0      2      1      0      0
## 2  3.24   12    22      2       0      1      1      3      1      0      0
## # ... with 13 more variables: west <dbl>, construc <dbl>, ndurman <dbl>,
## #   trcommpu <dbl>, trade <dbl>, services <dbl>, profserv <dbl>, profocc <dbl>,
## #   clerocc <dbl>, servocc <dbl>, lwage <dbl>, expersq <dbl>, tenursq <dbl>
```

- Nota. siempre activo tidyverse por el formato tidy.

# Cargar base de datos desde Excel

- Mediante ventanas, podemos importar datos desde Excel:



# Cargar base de datos: pc

- La función `getwd()` nos devuelve el directorio de trabajo (carpeta donde R guardará o buscará los archivos que indiquemos) y el comando `setwd()` nos permite modificarlo.
- Es preferible especificar el directorio de trabajo para poder acortar las direcciones de objetos.

```
# setwd("C:../Datos")
```

```
datawage <- read.delim("wage1.txt")
head(datawage[,1:7], n=5)
```

```
##   wage educ exper tenure nonwhite female married
## 1 3.10   11     2      0        0      1        0
## 2 3.24   12    22      2        0      1        1
## 3 3.00   11     2      0        0      0        0
## 4 6.00    8    44     28        0      0        1
## 5 5.30   12     7      2        0      0        1
```

# Utilidades con data.frame

- Las funciones `cbind()` y `rbind()` permiten concatenar atributos respecto a dim (combinar filas o columnas).
- Extraer el nombre de las columnas:

```
names(base_datos)
```

```
## [1] "nota" "nombre" "menor"
```

```
dput(names(base_datos))
```

```
## c("nota", "nombre", "menor")
```



# Cargar base de datos: paquetes y sistema

```
#data()
```

```
#install.packages("wooldridge")
```

```
library(wooldridge)
```

```
head(wage1[,1:7], n=5)
```

```
##      wage educ exper tenure nonwhite female married
## 1 3.10    11     2      0         0      1         0
## 2 3.24    12    22      2         0      1         1
## 3 3.00    11     2      0         0      0         0
## 4 6.00     8    44     28         0      0         1
## 5 5.30    12     7      2         0      0         1
```

# Listas

- La lista es una colección de objetos de distintas magnitudes (el data frame solo acepta vectores de igual tamaño).

```
lista_a <- list(nombre = "USA",  
               datos = base_datos)
```

```
lista_a
```

```
## $nombre  
## [1] "USA"  
##  
## $datos  
##   nota nombre menor  
## 1   91    Luis FALSE  
## 2   76   Angel  TRUE  
## 3   68   Dario FALSE  
## 4   78    Juan FALSE
```

# Listas

- Anexo un ejemplo de lista de base de datos:

```
list(list(nombre = "USA",
          datos = base_datos),

      list(nombre = "Dom",
            datos = c()))
```

```
## [[1]]
## [[1]]$nombre
## [1] "USA"
##
## [[1]]$datos
##      nota nombre menor
## 1    91    Luis FALSE
## 2    76   Angel  TRUE
## 3    68   Dario FALSE
## 4    78    Juan FALSE
##
##
## [[2]]
## [[2]]$nombre
## [1] "Dom"
```

# Listas

```
mylist <- list(edad,nombres,c=c(1,3))  
mylist
```

```
## [[1]]  
## [1]  8  4  2  6 10  9  
##  
## [[2]]  
## [1] "Maria"  "Jesus"  "Juan"   "Antonio" "Ana"  
##  
## $c  
## [1] 1 3
```

# Listas

```
matriz1 <- matrix(1:6, nrow = 2)
matriz2 <- matrix(7:12, nrow = 2)
matriz3 <- matrix(13:18, nrow = 2)

# Crear una lista de matrices
lista_de_matrices <- list(matriz1, matriz2, matriz3)
lista_de_matrices
```

```
## [[1]]
##      [,1] [,2] [,3]
## [1,]    1    3    5
## [2,]    2    4    6
##
## [[2]]
##      [,1] [,2] [,3]
## [1,]    7    9   11
## [2,]    8   10   12
##
## [[3]]
##      [,1] [,2] [,3]
## [1,]   13   15   17
## [2,]   14   16   18
```

## Section 6

# Subsetting and Element Extraction (indexación)

# Indexar vectores

- R permite acceder a un elemento de un vector añadiendo el nombre de un vector en un índice entre corchetes `[]`.
- El vector índice, puede indicar parte de otro vector y ser de tres tipos:
  - Vector de *números enteros*: en caso de ser positivos son concatenados y en caso de ser negativos son omitidos. No hace falta sea de igual longitud al vector seleccionado.
  - Vector lógico: los valores correspondientes a TRUE son seleccionados.
  - Vector de nombres: solo se aplica cuando el vector tiene el atributo names.

# Indexar vectores

```
edad
```

```
## [1] 8 4 2 6 10 9
```

```
edad[5] # El quinto elemento
```

```
## [1] 10
```

```
edad[c(1,3,6)] # Posiciones específicas
```

```
## [1] 8 2 9
```

```
edad[length(edad)]
```

```
## [1] 9
```

```
edad[1:5] # Del primer al quinto elemento
```

```
## [1] 8 4 2 6 10
```



# Omitir o sobrecribir

- Sobrecribir:

```
edad
```

```
## [1] 8 4 2 6 10 9
```

```
edad[5] <- 8
edad
```

```
## [1] 8 4 2 6 8 9
```

- Omitir:

```
edad[-5] # Todos los elementos, menos el quinto
```

```
## [1] 8 4 2 6 9
```

# Indexación por números

- El acceso a los elementos individuales de un vector no solamente es para consulta o lectura, sino también para su modificación o escritura.

```
# Operaciones con elementos
```

```
edad[4]+edad[2]
```

```
## [1] 10
```

```
# Guardar los resultados en una posición
```

```
edad[1] <- edad[2] + edad[5] - 7
```

```
edad
```

```
## [1] 5 4 2 6 8 9
```

# Indexación lógica

- El uso de operadores lógicos también permite el uso de **indexación lógica**. El mismo, funciona como un filtro condicional para acceder a subconjuntos de datos que cumplen con determinadas condiciones.

```
edad[edad>2] # Un vector solo con las edades mayores a 2
```

```
## [1] 5 4 6 8 9
```

```
edad[3 <= edad & edad <= 7] # Un vector solo con las edades comprendidos entre 3 y
```

```
## [1] 5 4 6
```

```
sum(3 <= edad & edad <= 7) #número de elementos contenidos en un rango determinado
```

```
## [1] 3
```

# Indexación lógica

```
ingresos <- rnorm(10,mean=20,sd=5)  
ingresos[ingresos>10]
```

```
## [1] 24.80439 24.88727 27.67358 29.48933 28.09376 29.17022 21.28451 24.70070  
## [9] 12.84230 18.94330
```

```
ingresos[ingresos>10]<-0
```

# Indexación mediante which

- La función `which` suele ser útil dado que indica la posición del vector donde se encuentra un número determinado [ver `which.min()` `which.max()`].

```
edadx <- c(15,22,15,19,17)
vec_log <- edadx <= 17
vec_log
```

```
## [1] TRUE FALSE TRUE FALSE TRUE
```

```
which(vec_log)
```

```
## [1] 1 3 5
```

# Indexación mediante which

- En el caso de operadores lógicos podemos:
  - Posiciones de personas con más de 5 años.
  - Posiciones de personas con edad menor al promedio.
  - Posiciones de la person con mayor edad.

```
which(edad>5)
```

```
## [1] 4 5 6
```

```
which(edad<mean(edad))
```

```
## [1] 1 2 3
```

```
which(edad==max(edad))
```

```
## [1] 6
```

# Indexación de matrices

- En caso de una matriz bidimensional se debe especificar  $[nfilas, ncol]$  tanto fila como columna. Luego, aplican las mismas reglas vistas hasta aquí.

```
m1 <- matrix(1:12, nrow=3)
m1
```

```
##      [,1] [,2] [,3] [,4]
## [1,]    1    4    7   10
## [2,]    2    5    8   11
## [3,]    3    6    9   12
```

```
m1[3,2] #Obtener el elemento de la fila 2, columna 3
```

```
## [1] 6
```

```
m1[2,] #Llamar todos los elementos de la fila 2
```

```
## [1]  2  5  8 11
```

```
m1[2,1:2]
```

```
## [1] 2 5
```

# Indexación de matrices

```
m1
```

```
##      [,1] [,2] [,3] [,4]
## [1,]    1    4    7   10
## [2,]    2    5    8   11
## [3,]    3    6    9   12
```

```
m1[nrow(m1),ncol(m1)]
```

```
## [1] 12
```

```
"["(m1,1:2,2)
```

```
## [1] 4 5
```



# Indexación de data.frame

- Cuando se trabaja con data.frame, se puede acceder a sus subconjuntos, usando el simbolo de \$, a su izquierda se coloca el nombre de la lista y a la derecha (o directamente luego de utilizar el comando attach), o utilizando [].
- Dentro del corchete debemos indicar las indicaciones tanto para filas como para columnas.

[fila,columna]

- No colocar una de estas indicaciones R asume deseas todas las filolas co columnas.

# Indexación de data.frame

- Seleccionando columnas:

```
Mydatos$edad
```

```
## [1] 8 4 2 6 10 9
```

```
Mydatos[,2]
```

```
## [1] 8 4 2 6 10 9
```

```
Mydatos[, 'edad']
```

```
## [1] 8 4 2 6 10 9
```

# Indexación de data.frame

- La opción de doble también corchete (`[[ ]]`) permite acceder a una columna determinada.

```
Mydatos[[2]]
```

```
## [1] 8 4 2 6 10 9
```

```
Mydatos[2]
```

```
##      edad
## 1      8
## 2      4
## 3      2
## 4      6
## 5     10
## 6      9
```

# Indexación de data.frame

- Acceder a elementos de una fila, equivalente a realizar filtros entre usuarios de Excel.

```
Mydatos[edad>4,] #Establece la base solo con mayores de 4 años
```

```
##      sexofactor edad  edaM  edaMh X.edaMh  edaMhm xorEdadMh
## 1      Hombre    8  TRUE   TRUE   FALSE   TRUE     FALSE
## 4      Mujer    6  TRUE  FALSE   TRUE    TRUE     TRUE
## 5      Hombre   10  TRUE   TRUE   FALSE   TRUE     FALSE
## 6      Hombre    9  TRUE   TRUE   FALSE   TRUE     FALSE
```

```
Mydatos[sexofactor=="Mujer",] #Establece la base solo con mujeres
```

```
##      sexofactor edad  edaM  edaMh X.edaMh  edaMhm xorEdadMh
## 2      Mujer    4  FALSE  FALSE   TRUE   FALSE     FALSE
## 4      Mujer    6   TRUE  FALSE   TRUE    TRUE     TRUE
```

# Indexación de data.frame

- Combinar filas y columnas:  
 ' En este caso, las columnas representan variables, mientras que las filas corresponden observaciones. Por tanto, condicional a filas es similar a realizar filtros o análisis condicional en Excel.

```
Mydatos[sexofactor=="Hombre",c(1:3)]
```

```
##      sexofactor edad  edaM
## 1      Hombre    8  TRUE
## 3      Hombre    2 FALSE
## 5      Hombre   10  TRUE
## 6      Hombre    9  TRUE
```

- **Ejercicios.** Dado el siguiente data.frame, obtenga:
  - Notas y el número de estudiantes que aprobaron el curso ( $> 70$ ).
  - Nota media de hombres y mujeres (por sexo).
  - Nota promedio de las mujeres que aprobaron.
  - Nota promedio de las mujeres que aprobaron y eran de la provincia a.
  - Nota promedio de las mujeres que aprobaron y eran de la provincia a o c.
  - Use indexación por posición para indicar de que provincia era la persona con la nota más alta.
  - Obtenga un data.frame omitiendo los reprobados.

```
##   nota mujer prov
## 1    75     1    a
## 2    80     1    b
## 3    60     0    a
## 4    85     1    c
## 5    70     0    a
## 6    65     0    b
```

# Indexación de lista

- Un ejemplo de la utilizadas de las listas se obtienen de la salidas de funciones como la usada para estimar modelos de regresión lineal:

```
model <- lm(speed~dist, data=cars)

is.list(model)
```

```
## [1] TRUE
```

```
names(model)
```

```
## [1] "coefficients" "residuals"      "effects"         "rank"
## [5] "fitted.values" "assign"          "qr"              "df.residual"
## [9] "xlevels"       "call"           "terms"           "model"
```

# Indexación de lista

```
mylist[1] #primer vector
```

```
## [[1]]  
## [1]  8  4  2  6 10  9
```

```
mylist[[1]]
```

```
## [1]  8  4  2  6 10  9
```

```
mylist[["c"]]
```

```
## [1] 1 3
```

```
mylist[[2]][1]
```

```
## [1] "Maria"
```

```
mylist$edad
```

```
## NULL
```



## Section 7

### **Guardar resultados**

# Exportar resultados en pantalla

- Cada vez que ejecutamos una orden en R se imprimen los resultados en pantallas, el comando sink permite guardar estas impresiones en un archivo palno txt.

```
sink("rfinal.txt")  
2+2
```

```
## [1] 4
```

```
sink()
```

- Adicionalmente, es posible salvar el ambiente de trabajo.

```
save.image("ambienteClase1.RData")
```

# Exportar a pdf

- R permite guardar el script, resultado de consola, historico de comandos, gráficos, listas u objetos.

```
# guardar resultados impresos en consola  
pdf("graph.pdf")
```

```
x<-rnorm(100)  
hist(x)  
dev.off()
```

```
## pdf  
## 2
```

# Guardar objetos

- Adicionalmente, podemos guardar lista/objetos de nuestro ambiente de trabajo en formato RData.

```
mi_lista <- list(  
  nombre = "Juan",  
  edad = 30,  
  ciudad = "Ocoa"  
)  
  
saveRDS(mi_lista, file = "mi_lista.RData")
```

- Para cargar la lista desde el archivo RData:

```
mi_lista_cargada <- readRDS("mi_lista.RData")
```

## Section 8

# Missing value

# Missing value

- Los valores perdidos en R se representan mediante NA (Not Available), estos se utiliza para representar valores faltantes o ausentes en un vector o en un conjunto de datos. .

```
edad3 <- c(21, 16, NA, 28, 38, 17)
mean(edad3, na.rm = TRUE)
```

```
## [1] 24
```

# Missing value

- R contiene una batería de funciones para trabajar con NA.

```
(x <- c(NA,1:5))
```

```
## [1] NA  1  2  3  4  5
```

```
is.na(x)
```

```
## [1] TRUE FALSE FALSE FALSE FALSE
```

```
x[!is.na(x)]
```

```
## [1] 1 2 3 4 5
```

```
(x[is.na(x)] <- mean(x, na.rm = T))
```

```
## [1] 3
```

## Section 9

# Vectorización de funciones\*



# Vectorización de funciones\*

- Aquí solo se presentan algunos ejemplos como forma de motivar contenido futuro.

```
tapply(edad, sexofactor, mean)
```

```
## Hombre  Mujer
##      6      5
```

```
by(edad, sexofactor, mean)
```

```
## sexofactor: Hombre
## [1] 6
## -----
## sexofactor: Mujer
## [1] 5
```

# Vectorización de funciones

- La función `split` nos permite segmentar un vector según las clases incluidas en un factor, generando una lista.
- La función vectorizada `sapply` permite realizar una orden sobre cada uno de los elementos de la lista (genera un vector, `lapply` una lista).

```
split(edad, sexo)
```

```
## $f  
## [1] 4 6  
##  
## $m  
## [1] 5 2 8 9
```

```
sapply(split(edad, sexo), mean)
```

```
## f m  
## 5 6
```

# Vectorización de funciones

```
aggregate(edad,list(sexo),mean)
```

```
##   Group.1 x  
## 1      f 5  
## 2      m 6
```

# Vectorización de funciones

- Seleccionar todas las columnas que cumplen con determinada condición:

```
Mydatos[,sapply(Mydatos,is.logical)]
```

```
##      edaM edaMh X.edaMh edaMhm xorEdadMh
## 1  TRUE  TRUE   FALSE   TRUE     FALSE
## 2 FALSE FALSE    TRUE  FALSE     FALSE
## 3 FALSE FALSE    TRUE   TRUE     TRUE
## 4  TRUE FALSE    TRUE   TRUE     TRUE
## 5  TRUE  TRUE   FALSE   TRUE     FALSE
## 6  TRUE  TRUE   FALSE   TRUE     FALSE
```

# Indexación vectorizada

- De una lista de matrices, deseamos recuperar la primera columna de cada una de las matrices:

```
lista_de_matrices[[1]]
```

```
##      [,1] [,2] [,3]
## [1,]    1    3    5
## [2,]    2    4    6
```

```
lapply(lista_de_matrices, function(x) x[, 1])
```

```
## [[1]]
## [1] 1 2
##
## [[2]]
## [1] 7 8
##
## [[3]]
## [1] 13 14
```

# Indexación vectorizada

- Podemos usar vectorización para crear un lista con distintos operadores:

```
sexo <- c("f","f","m","f","m")
lapply(c("f","m"), function(x) which(sexo==x))
```

```
## [[1]]
## [1] 1 2 4
##
## [[2]]
## [1] 3 5
```

```
split(1:length(sexo),sexo)
```

```
## $f
## [1] 1 2 4
##
## $m
## [1] 3 5
```

## Section 10

## Referencias

# Referencias

- ❶ Becker, R. A., Chambers, J. M. and Wilks, A. R. (1988). The New S Language. Wadsworth and Brooks/Cole.
- ❷ Castro, E. (2020). Diseño experimental y análisis de datos. Universidad Andrés Bello.
- ❸ Conesa, D. (2013). "Curso introducción R". Universidad de Valencia, Dept. de estadística e investigación operativa. Valencia, España.
- ❹ Contreras J.M., Molina E. y Arteaga P. "Introducción a la programación estadística con R".
- ❺ Crawley, M. The R Book. Imperial College London.
- ❻ Grolemond, G. (2014). Hands-On Programming with R.
- ❼ Harrison, G. (2020). "Getting Started with R for Measurement". Universidad de Hawai.
- ❽ James, Gareth; Witten, Daniela; Hastie, Trevor and Tibshirani, Robert. An Introduction to Statistical Learning. Springer Texts in Statistics. USA.
- ❾ Matloff, N. (2009). "The Art of R Programming"
- ❿ Narayanachar, P.; Ramaiah, S and Manjunath, B.G. (). "A course in Statistics with R". Wiley. This edition first published 2016.
- ⓫ Pruim, R. (2011). Computational Statistics Using R and R Studio An Introduction for Scientists. SC 11 Education Program.



# Referencias

- ① Romero, F. (nd). Matrices, marcos de datos y lectura de datos en R. Máster en Lógica, Computación e Inteligencia Artificial. Universidad de Sevilla.
- ② Santana (2013). "El Arte de Programar en R".
- ③ Teetor, P. (2011). R Cookbook. United States of America.
- ④ R Core Team (2018). R: A language and environment for statistical computing. R Foundation for Statistical Computing, Vienna, Austria.
- ⑤ Venable, W.; Smith, D. (2021). An Introduction to R. R Core Team.
- ⑥ Verzani, J. (2002). simpleR - Using R for Introductory Statistics.
- ⑦ Wickham, H. (2015). Advanced R. Taylor and Francis, LLC.